

Atividade Prática 1.1

Considere o contexto do planejamento e da operação de sistemas de energia elétrica, no qual empresas concessionárias necessitam prever a demanda futura de consumo para garantir a estabilidade do fornecimento, otimizar custos operacionais e evitar sobrecargas na rede.

Suponha que a concessionária disponha de um banco de dados histórico contendo medições horárias de consumo agregado de energia elétrica, registradas ao longo de vários anos, bem como informações associadas a variáveis climáticas (como temperatura e umidade), características temporais (hora do dia, dia da semana, sazonalidade) e indicadores de eventos excepcionais (feriados, ondas de calor, etc.).

O objetivo é utilizar esses dados históricos para construir um modelo preditivo capaz de estimar a demanda total de energia elétrica em períodos futuros, em um horizonte de curto prazo (por exemplo, horas ou dias à frente), de modo a subsidiar decisões operacionais, como despacho de geração, alocação de reservas e planejamento da manutenção da rede.

Admita que, a cada novo período, novas observações de consumo tornam-se disponíveis e podem ser incorporadas ao processo de modelagem. Nesse contexto, identifique os componentes fundamentais do problema de aprendizado de máquina, de acordo com a formulação clássica:

Solução. Nesse contexto, podemos identificar os componentes fundamentais como:

- **Tarefa (T):** construir um modelo preditivo capaz de estimar a demanda total de energia elétrica em períodos futuros, em um horizonte de curto prazo (por exemplo, horas ou dias à frente).
- **Medida de desempenho (P):** medidas de desempenho de um modelo de regressão, como *RMSE* (Root Mean Squared Error) ou *MAE* para medir a demanda de energia predita. Além dessas medidas para avaliar previsões pontuais, podemos utilizar medidas para avaliar o intervalo de previsão do modelo, como o Winkler Score ou CRPS (Continuous Ranked Probability Score).
- **Experiência (E):** banco de dados histórico contendo medições horárias de consumo agregado de energia elétrica, registradas ao longo de vários anos, bem como informações associadas a variáveis climáticas (como temperatura e umidade), características temporais (hora do dia, dia da semana, sazonalidade) e indicadores de eventos excepcionais (feriados,

ondas de calor, etc.). A experiência também é atualizada iterativamente à medida que novas observações se tornam disponíveis.

Atividade Prática 1.2

Considere um estudo observacional retrospectivo cujo objetivo geral é *examinar a dinâmica temporal de mutações virais e prever quantitativamente seu comportamento futuro*, de modo a caracterizar padrões evolutivos associados à circulação viral em diferentes contextos epidemiológicos. O estudo baseia-se em dados provenientes de um consórcio de laboratórios públicos e universitários responsáveis pelo *sequenciamento genômico sistemático* de amostras virais coletadas rotineiramente em serviços de saúde, no âmbito de programas institucionais de vigilância genômica voltados ao monitoramento da diversidade genética viral em escala populacional. O banco de dados é composto por *aproximadamente 4.500 genomas virais completos ou quase completos*, coletados entre 2020 e 2024, abrangendo múltiplos períodos epidêmicos, diferentes regiões geográficas e variados perfis demográficos. Cada genoma encontra-se associado a um conjunto mínimo de informações clínicas e epidemiológicas do hospedeiro no momento da coleta, refletindo restrições operacionais típicas de sistemas reais de vigilância genômica. Para cada amostra viral, estão disponíveis:

- a *sequência genômica consenso*, alinhada a uma sequência de referência específica para cada categoria viral;
- *listas de mutações* identificadas em relação à referência, incluindo substituições, inserções e deleções (ordem de grandeza típica: dezenas a centenas de mutações por genoma, a depender do grupo viral);
- *anotações funcionais* das mutações, discriminando regiões codificantes, proteínas estruturais e regiões regulatórias;
- *métricas de qualidade do sequenciamento*, tais como cobertura média (variando entre e leituras por base) e proporção de bases ambíguas (mediana inferior a 5%, com cauda direita em amostras de menor qualidade).

Associados a cada genoma, encontram-se ainda *metadados clínicos e epidemiológicos de granularidade limitada*, incluindo faixa etária do hospedeiro (em classes decenais), sexo biológico, status vacinal no momento da coleta (quando disponível), presença de comorbidades autorreferidas e cenário de atendimento (atenção primária, pronto atendimento ou hospitalização). Outros aspectos relevantes do conjunto de dados são descritos nos itens a seguir.

(I) Unidade de Análise e Estrutura dos Dados

A *unidade primária de análise* é a *amostra viral sequenciada*, associada a um indivíduo em um instante específico no tempo. Para fins de modelagem temporal supervisionada, as informações genômicas são *agregadas em janelas temporais sucessivas* (por exemplo, semanas epidemiológicas), a partir das quais são estimadas frequências relativas de mutações ou combinações de mutações. O conjunto de dados apresenta *estrutura hierárquica e temporal*, caracterizada por:

- agregação de amostras por região geográfica e período epidemiológico;
- distribuição temporal irregular das observações, com picos de amostragem associados a ondas epidêmicas;
- dependência temporal e filogenética entre os genomas analisados, decorrente de ancestrais evolutivos compartilhados.

Os dados genômicos foram obtidos por plataformas de sequenciamento, empregando protocolos laboratoriais que variaram ao longo do período de estudo. Consequentemente, *nem todas as informações estão completas para todas as amostras*, e a qualidade das sequências apresenta variação substancial, particularmente em períodos de alta incidência viral.

(II) Fenômeno de Interesse

O foco do estudo recai sobre a *dinâmica populacional de mutações virais ao longo do tempo*, compreendendo:

- a emergência, expansão ou extinção de mutações em janelas temporais sucessivas;
- o acúmulo diferencial de alterações genéticas em linhagens virais específicas;
- padrões de coocorrência entre mutações, potencialmente associados a restrições estruturais ou pressões seletivas;
- variações temporais e espaciais na *frequência relativa* de mutações individuais ou combinadas;
- associações entre trajetórias mutacionais e características epidemiológicas, como ondas epidêmicas, localização geográfica e status vacinal da população amostrada.

Esses fenômenos são *intrinsecamente temporais e multivariados* e são formulados, neste exercício, como um problema de aprendizado supervisionado, no qual informações observadas até um tempo são utilizadas para prever o comportamento das frequências mutacionais em um horizonte futuro .

(III) Desafios

A análise desse conjunto de dados envolve desafios metodológicos relevantes, incluindo:

- *alta dimensionalidade* dos dados genômicos;
- *dependência temporal e filogenética*, violando pressupostos de independência;
- *heterogeneidade temporal e espacial* da amostragem;
- presença de *ruído técnico* associado ao sequenciamento;
- *viéses de amostragem* decorrentes de estratégias de vigilância não aleatórias;
- necessidade de *particionamento temporal adequado* para treinamento e avaliação de modelos supervisionados, evitando vazamento de informação do futuro.

Decisões tomadas nas etapas iniciais – como definição da janela temporal, critérios de filtragem de sequências, agregação de mutações raras e construção de atributos temporais – podem condicionar a validade preditiva dos modelos.

(IV) Objetivos do Estudo

O objetivo do projeto é desenvolver uma *estratégia de aprendizado supervisionado*, fundamentada em métodos estatísticos, capaz de *predizer a evolução futura da frequência de mutações virais*, contribuindo para:

- a compreensão quantitativa dos processos evolutivos virais em escala populacional;
- o monitoramento prospectivo de mudanças genéticas potencialmente relevantes;
- o suporte a decisões em vigilância epidemiológica e genômica.

(V) Tarefa

Com base exclusivamente no cenário descrito, *elabore um diagrama (workflow)* que represente, de forma lógica e coerente, as *etapas de um projeto de aprendizado supervisionado aplicado à análise de mutações virais*. O diagrama deve contemplar, entre outros aspectos:

- a definição formal da tarefa preditiva e da variável-resposta temporal;
- a construção do conjunto de dados supervisionado a partir de janelas temporais;
- o pré-processamento e a engenharia de atributos temporais e genômicos;
- a seleção de *modelos supervisionados adequados a dados temporais* (por exemplo, regressão penalizada, métodos baseados em árvores ou modelos com regularização);
- estratégias de *validação temporal* (treinamento no passado e teste no futuro);

- critérios de avaliação baseados em *métricas de erro para regressão* e na capacidade de identificar *trajetórias de crescimento acelerado*;
- e a decisão final sobre o uso do modelo, com indicação de possíveis *etapas iterativas*.

O diagrama deve ser compreensível para uma *equipe multidisciplinar* composta por biólogos, epidemiologistas e cientistas de dados.

Solução. Primeiramente, vamos responder cada um dos itens separadamente para organizar tudo em um *workflow* organizado.

- **A definição formal da tarefa preditiva e da variável-resposta temporal:** o objetivo geral é examinar a dinâmica temporal de mutações virais e prever quantitativamente seu comportamento futuro. Para este cenário, temos um problema de regressão multivariada em séries temporais. Logo, a variável-resposta (y_t) pode ser definida como a frequência relativa (proporção) de uma mutação específica (ou linhagem) em relação ao total de genomas sequenciados na população de uma determinada região, agregada na semana epidemiológica t .
- **A construção do conjunto de dados supervisionado a partir de janelas temporais:** podemos considerar um modelo que utilize o tempo em semanas t que possa prever a semana $t + 1$. A janela de observações “desliza” ao longo de 2020 a 2024, semana à semana, criando múltiplos exemplos de treinamento a partir das mesmas séries históricas. O modelo utilizará características observadas na janela de tempo t (e suas defasagens $t - 1, t - 2$, etc.) para prever a proporção da mutação na semana $t + 1$.
- **o pré-processamento e a engenharia de atributos temporais e genômicos:** o pré-processamento poderá exigir o processamento de mutações extremamente raras (ex: presentes em $< 1\%$ das amostras globais) podendo ser agregadas em certas em categorias funcionais para mitigar o problema da esparsidade. Paralelamente, a engenharia de atributos envolverá a criação de variáveis de defasagem temporal (*lags*), associando ao instante t o histórico recente da série ($t - 1, t - 2$, etc.). Por fim, o espaço de características será enriquecido com covariáveis de contexto dinâmico, incluindo a cobertura vacinal agregada, a taxa móvel de hospitalizações regionais e os efeitos de interação espaço-temporal.
- **a seleção de modelos supervisionados adequados a dados temporais (por exemplo, regressão penalizada, métodos baseados em árvores ou modelos com regularização):** uma abordagem inicial seria utilizar um modelo de regressão linear com erros correlacionados no tempo ou um modelo ARIMAX (ARIMA com variáveis exógenas). No entanto, vale ressaltar que a aplicação do ARIMAX exige a projeção futura de cada

variável exógena X , o que adicionaria uma camada extra de incerteza. Outras estratégias para comparar as capacidades preditivas poderiam ser o uso de métodos baseados em árvores (como Random Forest ou XGBoost) ou de Regressão Penalizada (como Lasso).

- **estratégias de validação temporal (treinamento no passado e teste no futuro):** a estratégia baseia-se na validação cruzada temporal, que respeita a ordenação cronológica dos dados. O processo garante que as janelas de validação ocorram sempre após as de treinamento, prevenindo que o modelo aprenda com o futuro. Concluída a etapa de validação cruzada para a seleção e o refinamento dos hiperparâmetros dos modelos candidatos, a validação final da capacidade preditiva ocorre aplicando o modelo a um cenário de teste separado, simulando o ambiente de aplicação dos modelos na prática.
- **critérios de avaliação baseados em métricas de erro para regressão e na capacidade de identificar trajetórias de crescimento acelerado:** $RMSE$ (Root Mean Squared Error) ou MAE para medir a precisão da frequência predita. Também podemos utilizar medidas para avaliar o intervalo de previsão, como o Winkler Score ou CRPS (Continuous Ranked Probability Score).
- **e a decisão final sobre o uso do modelo, com indicação de possíveis etapas iterativas:** se o $RMSE$ estiver abaixo de um limiar aceitável e a sensibilidade para crescimento acelerado for alta, o modelo é validado para produção conceitual. Também verificaremos qual o modelo mais preciso em termos de intervalos de predição.




Figura 1: Workflow do projeto (embora disposto de forma unidirecional, passos anteriores podem ser revisitados de forma iterativa sempre que necessário para o ajuste do modelo).