

Atividade Prática 2.8

Considere o conjunto de dados `PimaIndiansDiabetes`, disponibilizado na biblioteca `mlbench`, que reúne informações clínicas de mulheres da etnia Pima com o objetivo de investigar a presença de diabetes mellitus. A base contém variáveis fisiológicas e laboratoriais medidas em unidades e ordens de grandeza distintas, entre as quais destacam-se `glucose`, `pressure`, `insulin` e `mass`. Nesta atividade, pretende-se aplicar e comparar diferentes procedimentos de normalização como etapa de pré-processamento de variáveis contínuas, com foco na reescala dos dados e na análise dos intervalos resultantes. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- selecionar as variáveis contínuas `glucose`, `pressure`, `insulin` e `mass`;
- inspecionar os intervalos originais de variação dessas variáveis;
- aplicar, separadamente, os seguintes procedimentos de normalização:
 - normalização *min-max*;
 - normalização pelo valor máximo;
 - normalização por amplitude;
 - normalização baseada em quantis;

Ao final, devem ser comparados os resultados obtidos para cada procedimento de normalização, avaliando-se as diferenças nos intervalos de variação das variáveis selecionadas.

Solução. Carregando os dados com as variáveis solicitadas:

```
library(mlbench)
```

```
Warning: pacote 'mlbench' foi compilado no R versão 4.5.3
```

```
library(dplyr)
```

```
Anexando pacote: 'dplyr'
```

Os seguintes objetos são mascarados por 'package:stats':

```
filter, lag
```

Os seguintes objetos são mascarados por 'package:base':

```
intersect, setdiff, setequal, union
```

```
data("PimaIndiansDiabetes")

df <- PimaIndiansDiabetes %>%
  select(glucose, pressure, insulin, mass)

head(df)
```

	glucose	pressure	insulin	mass
1	148	72	0	33.6
2	85	66	0	26.6
3	183	64	0	23.3
4	89	66	94	28.1
5	137	40	168	43.1
6	116	74	0	25.6

```
summary(df)
```

	glucose	pressure	insulin	mass
Min.	: 0.0	Min. : 0.00	Min. : 0.0	Min. : 0.00
1st Qu.:	99.0	1st Qu.: 62.00	1st Qu.: 0.0	1st Qu.:27.30
Median :	117.0	Median : 72.00	Median : 30.5	Median :32.00
Mean :	120.9	Mean : 69.11	Mean : 79.8	Mean :31.99
3rd Qu.:	140.2	3rd Qu.: 80.00	3rd Qu.:127.2	3rd Qu.:36.60
Max.	:199.0	Max. :122.00	Max. :846.0	Max. :67.10

Foram criadas funções para cada transformação e os valores foram armazenados no dataframe resultados.

```

norm_min_max <- function(x) (x - min(x, na.rm = TRUE)) / (max(x, na.rm = TRUE) - min
norm_max      <- function(x) x / max(x, na.rm = TRUE)
norm_amplitude <- function(x) x / (max(x, na.rm = TRUE) - min(x, na.rm = TRUE))
norm_quantil   <- function(x) rank(x) / length(x)

resultados <- data.frame(
  Original  = df$glucose,
  MinMax    = norm_min_max(df$glucose),
  Max       = norm_max(df$glucose),
  Amplitude = norm_amplitude(df$glucose),
  Quantil   = norm_quantil(df$glucose)
)

head(resultados)

```

	Original	MinMax	Max	Amplitude	Quantil
1	148	0.7437186	0.7437186	0.7437186	0.81054688
2	85	0.4271357	0.4271357	0.4271357	0.09895833
3	183	0.9195980	0.9195980	0.9195980	0.95703125
4	89	0.4472362	0.4472362	0.4472362	0.13216146
5	137	0.6884422	0.6884422	0.6884422	0.72200521
6	116	0.5829146	0.5829146	0.5829146	0.49088542

Observemos o intervalo de cada transformação:

```
sapply(resultados, range)
```

	Original	MinMax	Max	Amplitude	Quantil
[1,]	0	0	0	0	0.00390625
[2,]	199	1	1	1	1.00000000

Nestes cenário específico, ambas as transformações min-max, pelo máximo e pela amplitude resultaram em um intervalo entre 0 e 1. Enquanto que a transformação pelo quantil, teve o valor mínimo de seu intervalo um pouco superior ao zero.

Atividade Prática 2.9

Considere o conjunto de dados `lung`, disponibilizado na biblioteca `survival`, que reúne informações clínicas de pacientes diagnosticados com câncer de pulmão, incluindo variáveis demográficas, fisiológicas e indicadores do estado funcional. A base contém variáveis contínuas medidas em escalas distintas, o que motiva a aplicação de procedimentos de padronização como etapa de pré-processamento. Nesta atividade, pretende-se aplicar e comparar diferentes procedimentos de padronização de variáveis contínuas, com o objetivo de remover diferenças artificiais de escala e analisar as propriedades resultantes das variáveis transformadas. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- selecionar variáveis contínuas de interesse clínico presentes no conjunto de dados;
- inspecionar estatísticas descritivas básicas das variáveis selecionadas nos dados originais;
- aplicar, separadamente, os seguintes procedimentos de padronização:
 - padronização *z-score* baseada na média e no desvio-padrão amostrais;
 - padronização baseada na mediana e no intervalo interquartil;

Ao final, devem ser comparados os resultados obtidos para cada procedimento de padronização, avaliando-se as diferenças nas estatísticas descritivas das variáveis transformadas e a adequação de cada abordagem ao conjunto de dados considerado.

Solução. Carregando os dados de câncer:

```
data(cancer, package="survival")
head(cancer)
```

	inst	time	status	age	sex	ph.ecog	ph.karno	pat.karno	meal.cal	wt.loss
1	3	306	2	74	1	1	90	100	1175	NA
2	3	455	2	68	1	0	90	90	1225	15
3	3	1010	1	56	1	0	90	90	NA	15
4	5	210	2	57	1	1	90	60	1150	11
5	1	883	2	60	1	0	100	90	NA	0
6	12	1022	1	74	1	1	50	80	513	0

Padronização *z-score* baseada na média e no desvio-padrão amostrais:

```
cancer_zscore <- as.data.frame(cancer %>%
  select(where(is.numeric)) %>%
  apply(.,2,scale))

head(cancer_zscore)
```

	inst	time	status	age	sex	ph.ecog
1	-0.9740609	0.00364377	0.6165578	1.2732338	-0.8057999	0.06750247
2	-0.9740609	0.71099318	0.6165578	0.6119643	-0.8057999	-1.32550309
3	-0.9740609	3.34575103	-1.6147943	-0.7105747	-0.8057999	-1.32550309
4	-0.7331984	-0.45209813	0.6165578	-0.6003631	-0.8057999	0.06750247
5	-1.2149235	2.74284248	0.6165578	-0.2697283	-0.8057999	-1.32550309
6	0.1098206	3.40271877	-1.6147943	1.2732338	-0.8057999	0.06750247
	ph.karno	pat.karno	meal.cal	wt.loss		
1	0.6539344	1.370731178	0.6122240	NA		
2	0.6539344	0.686885246	0.7365480	0.39332291		
3	0.6539344	0.686885246	NA	0.39332291		
4	0.6539344	-1.364652547	0.5500619	0.08890662		
5	1.4650989	0.686885246	NA	-0.74823815		
6	-2.5907237	0.003039315	-1.0338268	-0.74823815		

Padronização baseada na mediana e no intervalo interquartil

```
library(tidyr)

iqr_score <- function(x) {
  (x - median(x, na.rm = TRUE)) / IQR(x, na.rm = TRUE)
}

cancer_iqr_score <- as.data.frame(cancer %>%
  select(where(is.numeric)) %>%
  apply(.,2,iqr_score))

head(cancer_iqr_score)
```

	inst	time	status	age	sex	ph.ecog	ph.karno	pat.karno
1	-0.61538462	0.2198041	0	0.8461538	0	0	0.6666667	1.0

2	-0.61538462	0.8683351	0	0.3846154	0	-1	0.6666667	0.5
3	-0.61538462	3.2840044	-1	-0.5384615	0	-1	0.6666667	0.5
4	-0.46153846	-0.1980413	0	-0.4615385	0	0	0.6666667	-1.0
5	-0.76923077	2.7312296	0	-0.2307692	0	-1	1.3333333	0.5
6	0.07692308	3.3362350	-1	0.8461538	0	0	-2.0000000	0.0

	meal.cal	wt.loss
1	0.3883495	NA
2	0.4854369	0.5079365
3	NA	0.5079365
4	0.3398058	0.2539683
5	NA	-0.4444444
6	-0.8970874	-0.4444444

Comparando algumas medidas de centralidade e dispersão após transformações:

```
resumo_zscore <- data.frame(
  Media = sapply(cancer_zscore, mean, na.rm = TRUE),
  Desvio = sapply(cancer_zscore, sd, na.rm = TRUE),
  Minimo = sapply(cancer_zscore, min, na.rm = TRUE),
  Maximo = sapply(cancer_zscore, max, na.rm = TRUE),
  Amplitude = sapply(cancer_zscore, function(x) diff(range(x, na.rm = TRUE)))
)

resumo_robusta <- data.frame(
  Mediana = sapply(cancer_iqr_score, median, na.rm = TRUE),
  IQR = sapply(cancer_iqr_score, IQR, na.rm = TRUE),
  Minimo = sapply(cancer_iqr_score, min, na.rm = TRUE),
  Maximo = sapply(cancer_iqr_score, max, na.rm = TRUE),
  Amplitude = sapply(cancer_iqr_score, function(x) diff(range(x, na.rm = TRUE)))
)

round(resumo_zscore, 4)
```

	Media	Desvio	Minimo	Maximo	Amplitude
inst	0	1	-1.2149	2.6389	3.8538
time	0	1	-1.4253	3.4027	4.8280
status	0	1	-1.6148	0.6166	2.2314
age	0	1	-2.5842	2.1549	4.7391

sex	0	1	-0.8058	1.2356	2.0414
ph.ecog	0	1	-1.3255	2.8535	4.1790
ph.karno	0	1	-2.5907	1.4651	4.0558
pat.karno	0	1	-3.4162	1.3707	4.7869
meal.cal	0	1	-2.0707	4.1555	6.2261
wt.loss	0	1	-2.5747	4.4268	7.0016

```
round(resumo_robusta, 4)
```

	Mediana	IQR	Minimo	Maximo	Amplitude
inst	0	1	-0.7692	1.6923	2.4615
time	0	1	-1.0903	3.3362	4.4266
status	0	1	-1.0000	0.0000	1.0000
age	0	1	-1.8462	1.4615	3.3077
sex	0	1	0.0000	1.0000	1.0000
ph.ecog	0	1	-1.0000	2.0000	3.0000
ph.karno	0	1	-2.0000	1.3333	3.3333
pat.karno	0	1	-2.5000	1.0000	3.5000
meal.cal	0	1	-1.7068	3.1553	4.8621
wt.loss	0	1	-1.9683	3.8730	5.8413

Podemos observar que medida de centro e dispersão respectiva para cada padronização é respectivamente 0 e 1, como esperado. A diferença é a amplitude de cada padronização, onde a padronização robusta demonstra apresentar um valor menor do que a padronização z-score.

Atividade Prática 2.10

Considere o conjunto de dados `ToothGrowth`, que descreve o efeito da suplementação de vitamina C sobre o crescimento odontológico em cobaias. A variável `len`, correspondente ao comprimento do dente, é contínua, estritamente positiva e apresenta assimetria, o que motiva a aplicação de uma transformação como etapa de pré-processamento. Nesta atividade, pretende-se aplicar a transformação de Box-Cox à variável `len`, com o objetivo de modificar a escala dos dados e avaliar o efeito da transformação sobre as características empíricas da distribuição. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- inspecionar a distribuição empírica da variável `len`;
- estimar o parâmetro da transformação de Box-Cox;
- aplicar a transformação de Box-Cox à variável `len`;

Ao final, devem ser comparadas as distribuições e estatísticas descritivas da variável `len` antes e após a aplicação da transformação, avaliando-se as alterações introduzidas pelo procedimento.

Solução. Obtendo os dados:


```
data("ToothGrowth")
df_tooth <- ToothGrowth

summary(df_tooth$len)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
4.20	13.07	19.25	18.81	25.27	33.90

Vamos inspecionar a distribuição da variável `len`:

```
par(mfrow = c(1, 3)) # Divide a área de plotagem
hist(df_tooth$len, main = "Histograma Original", xlab = "Comprimento (len)", col = "lightblue")
qqnorm(df_tooth$len, main = "Q-Q Plot Original")
qqline(df_tooth$len, col = "red")
boxplot(df_tooth$len, main = "Box-plot Original", ylab = "Comprimento (len)")
```



Visualmente, aparenta existir uma boa simetria em sua distribuição, apesar existir uma mudança brusca em sua extremidade. Vamos analisar se há melhorias com uma transformação de Box-Cox.

Como visto em aula, primeiro precisamos estimar o parâmetro dessa transformação. Estarei buscando o lambda que maximize a função de verossimilhança:


```
library(MASS)
```

Anexando pacote: 'MASS'

O seguinte objeto é mascarado por 'package:dplyr':

```
select
```

```
bc_resultado <- boxcox(lm(len ~ 1, data = df_tooth), plotit = TRUE)
```



```
lambda_ideal <- bc_resultado$x[which.max(bc_resultado$y)]  
cat("O valor estimado para o parâmetro lambda é:", round(lambda_ideal, 4))
```

O valor estimado para o parâmetro lambda é: 0.9495

Vamos aplicar a transformação de Box-Cox com o lambda estimado:

```

aplica_boxcox <- function(y, lambda) {
  if (abs(lambda) < 1e-6) {
    return(log(y))
  } else {
    return((y^lambda - 1) / lambda)
  }
}

df_tooth$len_transformado <- aplica_boxcox(df_tooth$len, lambda_ideal)

```

Podemos agora comparar estatísticas dos dados originais com essa transformação:

```

estatisticas_comparativas <- data.frame(
  Estatistica = c("Mínimo", "1º Quartil", "Mediana", "Média", "3º Quartil", "Máximo"),
  Original = as.numeric(summary(df_tooth$len)),
  Transformado = as.numeric(summary(df_tooth$len_transformado))
)
print(estatisticas_comparativas)

```

	Estatistica	Original	Transformado
1	Mínimo	4.20000	3.060952
2	1º Quartil	13.07500	11.039172
3	Mediana	19.25000	16.407528
4	Média	18.81333	15.958322
5	3º Quartil	25.27500	21.559655
6	Máximo	33.90000	28.829811

E visualmente, temos:

```


par(mfrow = c(2, 3))

hist(df_tooth$len, main = "Histograma Original", xlab = "len", col = "gray")
qqnorm(df_tooth$len, main = "Q-Q Plot Original")
qqline(df_tooth$len, col = "red")
boxplot(df_tooth$len, main = "Box-plot Original", ylab = "len")

hist(df_tooth$len_transformado, main = "Histograma Transformado", xlab = "len (Box-Cox)", col = "gray")
qqnorm(df_tooth$len_transformado, main = "Q-Q Plot Transformado")
qqline(df_tooth$len_transformado, col = "red")
boxplot(df_tooth$len_transformado, main = "Box-plot Transformado", ylab = "len (Box-Cox)")

```

```
qqnorm(df_tooth$len_transformado, main = "Q-Q Plot Transformado")
qqline(df_tooth$len_transformado, col = "red")
boxplot(df_tooth$len_transformado, main = "Box-plot Transformado", ylab = "len")
```



```
par(mfrow = c(1, 1))
```

Há singelas diferenças com essa transformação, reduzindo as estatísticas e produzindo um efeito de “achatamento” sutil em seu histograma, mas não aparentou ser tão significativo para estes dados.

Atividade Prática 2.11

Considere o conjunto de dados `iris`, que contém medidas morfológicas de flores do gênero *Iris*. A base inclui a variável categórica `Species`, composta por três níveis distintos: `setosa`, `versicolor` e `virginica`. Nesta atividade, pretende-se aplicar o procedimento de *one-hot encoding* à variável `Species`, com o objetivo de reespecificar sua representação por meio de variáveis indicadoras binárias. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- identificar os níveis observados da variável categórica `Species`;
- construir as variáveis indicadoras binárias correspondentes aos níveis identificados;

Ao final, deve-se verificar a estrutura do conjunto de dados e confirmar que a variável categórica original foi adequadamente representada por um conjunto de variáveis indicadoras binárias, refletindo corretamente os níveis originalmente observados.

Solução. Carregando os dados:

```
data(iris)

db <- iris
head(iris)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa

Podemos usar a função `model.matrix()` para aplicar o *one-hot encoding*:

```
X <- model.matrix(~ Species - 1, data = db)
head(X)
```

	Speciessetosa	Speciesversicolor	Speciesvirginica
1	1	0	0
2	1	0	0
3	1	0	0
4	1	0	0
5	1	0	0
6	1	0	0

E por fim, concatenamos nos dados originais.

```
iris_ohe <- cbind(db, X)
head(iris_ohe)
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species	Speciessetosa
1	5.1	3.5	1.4	0.2	setosa	1
2	4.9	3.0	1.4	0.2	setosa	1
3	4.7	3.2	1.3	0.2	setosa	1
4	4.6	3.1	1.5	0.2	setosa	1
5	5.0	3.6	1.4	0.2	setosa	1
6	5.4	3.9	1.7	0.4	setosa	1
	Speciesversicolor		Speciesvirginica			
1	0		0			
2	0		0			
3	0		0			
4	0		0			
5	0		0			
6	0		0			

Atividade Prática 2.13

Considere o conjunto de dados `PimaIndiansDiabetes2`, disponibilizado na biblioteca `mlbench`, que reúne informações clínicas e laboratoriais de mulheres da etnia Pima, com o objetivo de investigar a presença de diabetes mellitus. A variável `diabetes` representa a classe do desfecho (presença/ausência), enquanto as demais variáveis descrevem características fisiológicas e biométricas dos indivíduos. Nesta atividade, pretende-se aplicar o método *hold-out* para particionar o conjunto de dados em subconjuntos de treinamento e teste, com controle de reprodutibilidade por meio da fixação de uma semente aleatória e preservação da distribuição do desfecho por amostragem estratificada. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- Carregar o conjunto de dados `PimaIndiansDiabetes2` e atribuí-lo a um objeto de trabalho;
- Definir uma semente aleatória para garantir reprodutibilidade do particionamento;
- Realizar a divisão *hold-out* em proporções de 70% para treinamento e 30% para teste, utilizando amostragem estratificada em relação à variável `diabetes`;
- Obter e apresentar um resumo da divisão, incluindo:
 - A semente aleatória utilizada;
 - O número de observações e o percentual em cada subconjunto;
 - A distribuição das classes do desfecho (`diabetes`) nos conjuntos de treinamento e teste, em frequências e percentuais;

- Uma amostra das primeiras observações de cada subconjunto, para inspeção da estrutura.

Ao final, deve-se verificar a consistência do particionamento, confirmando que (i) as proporções especificadas foram atendidas e (ii) a distribuição do desfecho foi adequadamente preservada entre os subconjuntos de treinamento e teste.

Solução. Podemos utilizar a função `createDataPartition`, informando a porcentagem de dados particionado para os dados de treino da seguinte forma:

```
library(caret)
```

```
Warning: pacote 'caret' foi compilado no R versão 4.5.3
```

```
Carregando pacotes exigidos: ggplot2
```

```
Carregando pacotes exigidos: lattice
```

```
set.seed(1212)

data("PimaIndiansDiabetes2")
db <- PimaIndiansDiabetes2

train_index <- createDataPartition(db$diabetes, p = 0.7, list = FALSE)

head(train_index)
```

	Resample1
[1,]	1
[2,]	2
[3,]	3
[4,]	5
[5,]	6
[6,]	9

Assim, temos os dados de treino e teste com as dimensões dadas por:

```
train_set <- db[train_index,]
test_set <- db[-train_index,]
dim(train_set)
```

```
[1] 538    9
```

```
dim(test_set)
```

```
[1] 230    9
```

Podemos observar como ficou cada uma das partições separadamente:

```
head(train_set)
```

	pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age	diabetes
1	6	148	72	35	NA	33.6	0.627	50	pos
2	1	85	66	29	NA	26.6	0.351	31	neg
3	8	183	64	NA	NA	23.3	0.672	32	pos
5	0	137	40	35	168	43.1	2.288	33	pos
6	5	116	74	NA	NA	25.6	0.201	30	neg
9	2	197	70	45	543	30.5	0.158	53	pos

```
head(test_set)
```

	pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age	diabetes
4	1	89	66	23	94	28.1	0.167	21	neg
7	3	78	50	32	88	31.0	0.248	26	pos
8	10	115	NA	NA	NA	35.3	0.134	29	neg
16	7	100	NA	NA	NA	30.0	0.484	32	pos
17	0	118	84	47	230	45.8	0.551	31	pos
18	7	107	74	NA	NA	29.6	0.254	31	pos

Atividade Prática 2.14

Considere o conjunto de dados **SAheart**, disponibilizado na biblioteca **ElemStatLearn**, que reúne informações clínicas e fatores de risco associados a doença coronariana. A variável **chd** representa o desfecho binário (presença/ausência de doença coronariana), enquanto as demais

variáveis descrevem características demográficas e clínicas dos indivíduos. Nesta atividade, pretende-se aplicar o procedimento de validação cruzada *k-fold* para particionar o conjunto de dados em subconjuntos de treinamento e teste, com controle de reprodutibilidade por meio da fixação de uma semente aleatória e preservação da distribuição do desfecho por amostragem estratificada. O objetivo consiste em construir partições para $k \in \{3, 5, 10\}$ e resumir, para cada valor de k , as propriedades das divisões geradas. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- Carregar o conjunto de dados **SAheart** e atribuí-lo a um objeto de trabalho;
- Definir uma semente aleatória para garantir reprodutibilidade do particionamento;
- Para cada valor $k \in \{3, 5, 10\}$, realizar a divisão *k-fold* estratificada em relação à variável **chd**, obtendo a lista de índices de teste de cada *fold*;
- Para cada *fold* $i = 1, \dots, k$, construir os subconjuntos:
 - Conjunto de teste: observações pertencentes ao *fold* i ;
 - Conjunto de treinamento: observações complementares ao *fold* i ;
- Para cada *fold* i , obter e apresentar um resumo contendo:
 - O número do *fold*;
 - A semente aleatória utilizada;
 - O número de observações e o percentual em cada subconjunto;
 - A distribuição do desfecho (**chd**) nos conjuntos de treinamento e teste, em frequências e percentuais;
 - Uma amostra das primeiras observações de cada subconjunto, para inspeção da estrutura.

Ao final, deve-se verificar a consistência das partições geradas para $k \in \{3, 5, 10\}$, confirmando que (i) cada observação é utilizada exatamente uma vez como teste ao longo dos *folds* e (ii) a distribuição do desfecho foi adequadamente preservada entre treinamento e teste em cada *fold*.

Solução. Carregando o conjunto de dados:

```
data("SAheart", package = "ElemStatLearn")
df <- SAheart

df$chd <- as.factor(df$chd)
```


Criando um looping para aplicar a validação cruzada:

```
semente_utilizada <- 123
valores_k <- c(3, 5, 10)

tabela_distribuicao <- function(dados, nome_conjunto) {
  freq_abs <- table(dados$chd)
  freq_rel <- prop.table(freq_abs) * 100
  res <- data.frame(Classe = names(freq_abs), Absoluta = as.vector(freq_abs), Percentual = as.vector(freq_rel))
  print(res, row.names = FALSE)
}

for (k in valores_k) {
  set.seed(semente_utilizada)
  folds_teste <- createFolds(df$chd, k = k, list = TRUE, returnTrain = FALSE)

  todos_indices_teste <- unlist(folds_teste)

  consistente_tamanho <- length(unique(todos_indices_teste)) == nrow(df)

  for (i in 1:k) {
    cat(rep("-", 40), "\n")
    cat(sprintf("Resumo para o Fold %d de %d\n", i, k))
    cat(sprintf("Semente aleatória base: %d\n", semente_utilizada))
    idx_teste <- folds_teste[[i]]

    df_teste <- df[idx_teste, ]

    df_treino <- df[-idx_teste, ]

    n_total <- nrow(df)
    n_treino <- nrow(df_treino)
    n_teste <- nrow(df_teste)

    cat(sprintf("Conjunto de Treinamento: %d observações (%.2f%%)\n", n_treino, (n_treino/n_total)*100))
    cat(sprintf("Conjunto de Teste: %d observações (%.2f%%)\n\n", n_teste, (n_teste/n_total)*100))

    tabela_distribuicao(df_treino, "Treinamento")
    tabela_distribuicao(df_teste, "Teste")
  }
}
```

```

cat("Primeiras observações do subconjunto de Treinamento (amostra):\n")
print(head(df_treino, 3))
cat("\nPrimeiras observações do subconjunto de Teste (amostra):\n")
print(head(df_teste, 3))
cat("\n")
}
}

```

Resumo para o Fold 1 de 3

Semente aleatória base: 123

Conjunto de Treinamento: 308 observações (66.67%)

Conjunto de Teste: 154 observações (33.33%)

Classe Absoluta Percentual

0	201	65.26
---	-----	-------

1	107	34.74
---	-----	-------

Classe Absoluta Percentual

0	101	65.58
---	-----	-------

1	53	34.42
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
3 118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0	
6 132	6.20	6.47	36.21	Present	62	30.77	14.14	45	0	
7 142	4.05	3.38	16.20	Absent	59	20.81	2.62	38	0	

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1 160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1	
2 144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1	
4 170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1	

Resumo para o Fold 2 de 3

Semente aleatória base: 123

Conjunto de Treinamento: 308 observações (66.67%)

Conjunto de Teste: 154 observações (33.33%)

Classe Absoluta Percentual

0	202	65.58
1	106	34.42

Classe Absoluta Percentual

0	100	64.94
1	54	35.06

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
6	132	6.20	6.47	36.21	Present	62	30.77	14.14	45	0
12	134	14.10	4.44	22.39	Present	65	23.09	0.00	40	1

Resumo para o Fold 3 de 3

Semente aleatória base: 123

Conjunto de Treinamento: 308 observações (66.67%)

Conjunto de Teste: 154 observações (33.33%)

Classe Absoluta Percentual

0	201	65.26
1	107	34.74

Classe Absoluta Percentual

0	101	65.58
1	53	34.42

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
7	142	4.05	3.38	16.20	Absent	59	20.81	2.62	38	0
8	114	4.08	4.59	14.60	Present	62	23.11	6.72	58	1
10	132	0.00	5.80	30.96	Present	69	30.11	0.00	53	1

Resumo para o Fold 1 de 5

Semente aleatória base: 123

Conjunto de Treinamento: 370 observações (80.09%)

Conjunto de Teste: 92 observações (19.91%)

Classe Absoluta Percentual

0	242	65.41
1	128	34.59

Classe Absoluta Percentual

0	60	65.22
1	32	34.78

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
5	134	13.6	3.50	27.78	Present	60	25.99	57.34	49	1
10	132	0.0	5.80	30.96	Present	69	30.11	0.00	53	1
17	120	7.5	15.33	22.00	Absent	60	25.31	34.49	49	0

Resumo para o Fold 2 de 5

Semente aleatória base: 123

Conjunto de Treinamento: 369 observações (79.87%)

Conjunto de Teste: 93 observações (20.13%)

Classe Absoluta Percentual

0	241	65.31
1	128	34.69

Classe Absoluta Percentual

0	61	65.59
1	32	34.41

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
8	114	4.08	4.59	14.60	Present	62	23.11	6.72	58	1
11	206	6.00	2.95	32.27	Absent	72	26.81	56.06	60	1

Resumo para o Fold 3 de 5

Semente aleatória base: 123

Conjunto de Treinamento: 369 observações (79.87%)

Conjunto de Teste: 93 observações (20.13%)

Classe Absoluta Percentual

0	241	65.31
1	128	34.69

Classe Absoluta Percentual

0	61	65.59
1	32	34.41

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
6	132	6.20	6.47	36.21	Present	62	30.77	14.14	45	0
15	112	9.65	2.29	17.20	Present	54	23.53	0.68	53	0

Resumo para o Fold 4 de 5

Semente aleatória base: 123

Conjunto de Treinamento: 370 observações (80.09%)

Conjunto de Teste: 92 observações (19.91%)

Classe Absoluta Percentual

0	242	65.41
---	-----	-------

1	128	34.59
---	-----	-------

Classe Absoluta Percentual

0	60	65.22
---	----	-------

1	32	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
7	142	4.05	3.38	16.20	Absent	59	20.81	2.62	38	0
9	114	0.00	3.83	19.40	Present	49	24.86	2.49	29	0
13	118	0.00	1.88	10.05	Absent	59	21.57	0.00	17	0

Resumo para o Fold 5 de 5

Semente aleatória base: 123

Conjunto de Treinamento: 370 observações (80.09%)

Conjunto de Teste: 92 observações (19.91%)

Classe Absoluta Percentual

0	242	65.41
---	-----	-------

1	128	34.59
---	-----	-------

Classe Absoluta Percentual

0	60	65.22
---	----	-------

1	32	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
5	134	13.60	3.50	27.78	Present	60	25.99	57.34	49	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1
12	134	14.10	4.44	22.39	Present	65	23.09	0.00	40	1

Resumo para o Fold 1 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
---	-----	-------

1	144	34.62
---	-----	-------

Classe Absoluta Percentual

0	30	65.22
---	----	-------

1	16	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
5	134	13.60	3.50	27.78	Present	60	25.99	57.34	49	1
16	117	1.53	2.44	28.95	Present	35	25.89	30.03	46	0
19	158	2.60	7.46	34.07	Present	61	29.30	53.28	62	1

Resumo para o Fold 2 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
---	-----	-------

1	144	34.62
---	-----	-------

Classe Absoluta Percentual

0	30	65.22
---	----	-------

1	16	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
8	114	4.08	4.59	14.60	Present	62	23.11	6.72	58	1
11	206	6.00	2.95	32.27	Absent	72	26.81	56.06	60	1
45	114	0.00	2.99	9.74	Absent	54	46.58	0.00	17	0

Resumo para o Fold 3 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 415 observações (89.83%)

Conjunto de Teste: 47 observações (10.17%)

Classe Absoluta Percentual

0	271	65.3
---	-----	------

1	144	34.7
---	-----	------

Classe Absoluta Percentual

0	31	65.96
---	----	-------

1	16	34.04
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
14	132	0.00	1.87	17.21	Absent	49	23.63	0.97	15	0
36	122	4.26	4.44	13.04	Absent	57	19.49	48.99	28	1
42	144	0.04	3.38	23.61	Absent	30	23.75	4.66	30	0

Resumo para o Fold 4 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
---	-----	-------

1	144	34.62
---	-----	-------

Classe Absoluta Percentual

0	30	65.22
---	----	-------

1	16	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
9	114	0	3.83	19.40	Present	49	24.86	2.49	29	0
13	118	0	1.88	10.05	Absent	59	21.57	0.00	17	0
26	124	4	12.42	31.29	Present	54	23.23	2.06	42	1

Resumo para o Fold 5 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
1	144	34.62

Classe Absoluta Percentual

0	30	65.22
1	16	34.78

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
4	170	7.5	6.41	38.03	Present	51	31.99	24.26	58	1
12	134	14.1	4.44	22.39	Present	65	23.09	0.00	40	1
23	150	0.3	6.38	33.99	Present	62	24.64	0.00	50	0

Resumo para o Fold 6 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
1	144	34.62

Classe Absoluta Percentual

0	30	65.22
1	16	34.78

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
10	132	0.0	5.80	30.96	Present	69	30.11	0.00	53	1

17	120	7.5	15.33	22.00	Absent	60	25.31	34.49	49	0
18	146	10.5	8.29	35.36	Present	78	32.73	13.89	53	1

Resumo para o Fold 7 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
---	-----	-------

1	144	34.62
---	-----	-------

Classe Absoluta Percentual

0	30	65.22
---	----	-------

1	16	34.78
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
22	132	7.90	2.85	26.50	Present	51	26.16	25.71	44	0
24	138	0.60	3.81	28.66	Absent	54	28.70	1.46	58	0

Resumo para o Fold 8 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
---	-----	-------

1	144	34.62
---	-----	-------

Classe Absoluta Percentual

0	30	65.22
---	----	-------

1 16 34.78

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
4	170	7.50	6.41	38.03	Present	51	31.99	24.26	58	1
5	134	13.60	3.50	27.78	Present	60	25.99	57.34	49	1

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0
20	124	14.00	6.23	35.96	Present	45	30.09	0.00	59	1

Resumo para o Fold 9 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 416 observações (90.04%)

Conjunto de Teste: 46 observações (9.96%)

Classe Absoluta Percentual

0	272	65.38
1	144	34.62

Classe Absoluta Percentual

0	30	65.22
1	16	34.78

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
6	132	6.20	6.47	36.21	Present	62	30.77	14.14	45	0
7	142	4.05	3.38	16.20	Absent	59	20.81	2.62	38	0
33	122	6.60	5.58	35.95	Present	53	28.07	12.55	59	1

Resumo para o Fold 10 de 10

Semente aleatória base: 123

Conjunto de Treinamento: 415 observações (89.83%)

Conjunto de Teste: 47 observações (10.17%)

Classe Absoluta Percentual

0	271	65.3
---	-----	------

1	144	34.7
---	-----	------

Classe Absoluta Percentual

0	31	65.96
---	----	-------

1	16	34.04
---	----	-------

Primeiras observações do subconjunto de Treinamento (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
1	160	12.00	5.73	23.11	Present	49	25.30	97.20	52	1
2	144	0.01	4.41	28.61	Absent	55	28.87	2.06	63	1
3	118	0.08	3.48	32.28	Present	52	29.14	3.81	46	0

Primeiras observações do subconjunto de Teste (amostra):

	sbp	tobacco	ldl	adiposity	famhist	typea	obesity	alcohol	age	chd
15	112	9.65	2.29	17.20	Present	54	23.53	0.68	53	0
21	106	1.61	1.74	12.32	Absent	74	20.92	13.37	20	1
41	118	0.28	5.80	33.70	Present	60	30.98	0.00	41	1

Atividade Prática 2.15

Para esta atividade, será utilizado o conjunto de dados `birthwt`, disponibilizado na biblioteca `MASS`, que reúne informações maternas, comportamentais e obstétricas associadas ao peso ao nascer. A variável `low` indica a ocorrência de baixo peso ao nascer (desfecho binário de interesse), enquanto `bwt` representa o peso ao nascer em gramas. As demais variáveis (`age`, `lwt`, `race`, `smoke`, `ptl`, `ht`, `ui`, `ftv`) descrevem características associadas à gestação. Nesta atividade, pretende-se aplicar o método *bootstrap* com o objetivo principal de gerar subconjuntos de treinamento e teste que preservem, de forma aproximada, a estrutura do desfecho binário `low`. Em cada iteração, será construída uma amostra de treinamento por reamostragem com reposição e um subconjunto de teste composto pelas observações não selecionadas (*out-of-bag*, OOB), avaliando-se o comportamento dessas partições ao longo das iterações. O procedimento deve ser conduzido de acordo com as seguintes etapas:

- Carregar o conjunto de dados `birthwt` e atribuí-lo a um objeto de trabalho;

- Definir uma semente aleatória para garantir a reprodutibilidade do processo de reamostragem;
- Fixar o número de iterações bootstrap em $B = 10, \dots, 100$;
- Para cada iteração $b = 1, \dots, B$:
 - Gerar uma amostra bootstrap, com reposição, de tamanho igual ao número total de observações;
 - Definir o conjunto de treinamento como a amostra bootstrap obtida;
 - Definir o conjunto de teste como o conjunto OOB, formado pelas observações não selecionadas na amostra bootstrap;
 - Apresentar um resumo contendo:
 - * A iteração b ;
 - * A semente aleatória utilizada;
 - * O tamanho do conjunto de treinamento (bootstrap) e do conjunto de teste (OOB), incluindo o percentual do OOB em relação ao total;
 - * O número de observações distintas presentes no conjunto de treinamento e o número de repetições induzidas pela reamostragem;
 - * A proporção da variável `low` nos conjuntos de treinamento e OOB, em frequências e percentuais;

Ao final, deve-se verificar a consistência do procedimento, confirmando que, em cada iteração, o conjunto de treinamento é composto por reamostragem com reposição e que o conjunto OOB corresponde às observações não selecionadas, cuja dimensão pode variar entre iterações. Em seguida, deve-se selecionar uma iteração bootstrap cujo conjunto OOB apresente dimensão próxima de 36% do total de observações e preserve, de forma aproximada, a proporção da variável `low` observada na base original. Para a iteração selecionada, devem ser apresentados resumos descritivos dos conjuntos de treinamento bootstrap e OOB.

Solução. Carregando o conjunto de dados:

```
data("birthwt")
df <- birthwt

df$low <- factor(df$low, levels = c(0, 1), labels = c("Normal", "Baixo Peso"))
```

Proporção original para referência:

```
prop_original <- prop.table(table(df$low))["Baixo Peso"]
N <- nrow(df)
B <- 10
semente_base <- 67
```

Função auxiliar para remover a poluição visual do loop:

```
resumo_iteracao <- function(b, semente, df_treino, df_oob) {
  cat(sprintf("\n--- Iteração %d | Semente: %d ---\n", b, semente))
  cat(sprintf("Treino: %d obs | OOB: %d obs (%.2f%%)\n", nrow(df_treino), nrow(df_oob),
  cat(sprintf("Únicas no Treino: %d | Repetições: %d\n", length(unique(rownames(df_treino$low))), length(unique(rownames(df_oob$low))))

  cat("Desfecho (Treino vs OOB):\n")
  print(rbind(
    Treino = round(prop.table(table(df_treino$low)) * 100, 2),
    OOB     = round(prop.table(table(df_oob$low)) * 100, 2)
  ))
}
```

Criando o looping para aplicar o bootstrapping:

```
metricas <- data.frame()
lista_treino <- list()
lista_oob <- list()

for (b in 1:B) {
  set.seed(semente_base + b)

  idx_treino <- sample(1:N, size = N, replace = TRUE)
  idx_oob <- setdiff(1:N, unique(idx_treino))

  lista_treino[[b]] <- df[idx_treino, ]
  lista_oob[[b]] <- df[idx_oob, ]

  resumo_iteracao(b, semente_base + b, lista_treino[[b]], lista_oob[[b]])
}
```

```

perc_oob <- (length(idx_oob) / N) * 100
prop_oob_baixo <- prop.table(table(lista_oob[[b]]$low))["Baixo Peso"]

metricas <- rbind(metricas, data.frame(
  Iteracao = b,
  Desvio_OOB = abs(perc_oob - 36.0),
  Desvio_Prop = abs(as.numeric(prop_oob_baixo) - as.numeric(prop_original))
))
}

```

--- Iteração 1 | Semente: 68 ---

Treino: 189 obs | OOB: 70 obs (37.04%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

	Normal	Baixo Peso
Treino	76.19	23.81
OOB	62.86	37.14

--- Iteração 2 | Semente: 69 ---

Treino: 189 obs | OOB: 77 obs (40.74%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

	Normal	Baixo Peso
Treino	71.43	28.57
OOB	64.94	35.06

--- Iteração 3 | Semente: 70 ---

Treino: 189 obs | OOB: 66 obs (34.92%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

	Normal	Baixo Peso
Treino	64.02	35.98
OOB	74.24	25.76

--- Iteração 4 | Semente: 71 ---

Treino: 189 obs | OOB: 71 obs (37.57%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	67.20	32.80
--------	-------	-------

OOB	69.01	30.99
-----	-------	-------

--- Iteração 5 | Semente: 72 ---

Treino: 189 obs | OOB: 74 obs (39.15%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	64.55	35.45
--------	-------	-------

OOB	71.62	28.38
-----	-------	-------

--- Iteração 6 | Semente: 73 ---

Treino: 189 obs | OOB: 71 obs (37.57%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	73.02	26.98
--------	-------	-------

OOB	64.79	35.21
-----	-------	-------

--- Iteração 7 | Semente: 74 ---

Treino: 189 obs | OOB: 66 obs (34.92%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	65.61	34.39
--------	-------	-------

OOB	71.21	28.79
-----	-------	-------

--- Iteração 8 | Semente: 75 ---

Treino: 189 obs | OOB: 66 obs (34.92%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	65.61	34.39
--------	-------	-------

OOB	72.73	27.27
-----	-------	-------

--- Iteração 9 | Semente: 76 ---

Treino: 189 obs | OOB: 72 obs (38.10%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	66.67	33.33
--------	-------	-------

OOB	70.83	29.17
-----	-------	-------

--- Iteração 10 | Semente: 77 ---

Treino: 189 obs | OOB: 61 obs (32.28%)

Únicas no Treino: 189 | Repetições: 0

Desfecho (Treino vs OOB):

Normal Baixo Peso

Treino	67.72	32.28
--------	-------	-------

OOB	65.57	34.43
-----	-------	-------

Seleção da iteração ideal:

```
cat("\n=== SELEÇÃO DA ITERAÇÃO IDEAL ===\n")
```

=== SELEÇÃO DA ITERAÇÃO IDEAL ===

```
metricas$Score <- rank(metricas$Desvio_OOB) + rank(metricas$Desvio_Prop)
```

```
it_ideal <- metricas$Iteracao[which.min(metricas$Score)]
```

```
cat(sprintf("A iteração selecionada que melhor atende aos critérios é a b = %d.\n", it_ideal))
```

A iteração selecionada que melhor atende aos critérios é a b = 7.

```
df_treino_ideal <- lista_treino[[it_ideal]]
```

```
df_oob_ideal <- lista_oob[[it_ideal]]
```

```
cat("\n--- Resumo Descritivo: Conjunto de TREINAMENTO (Iteração Selecionada) ---\n")
```

--- Resumo Descritivo: Conjunto de TREINAMENTO (Iteração Selecionada) ---

```
print(summary(df_treino_ideal))
```

low	age	lwt	race
Normal :124	Min. :14.00	Min. : 80.0	Min. :1.000
Baixo Peso: 65	1st Qu.:20.00	1st Qu.:110.0	1st Qu.:1.000
	Median :23.00	Median :121.0	Median :2.000
	Mean :23.43	Mean :128.8	Mean :1.873
	3rd Qu.:27.00	3rd Qu.:138.0	3rd Qu.:3.000
	Max. :36.00	Max. :250.0	Max. :3.000

smoke	ptl	ht	ui
Min. :0.0000	Min. :0.0000	Min. :0.00000	Min. :0.000
1st Qu.:0.0000	1st Qu.:0.0000	1st Qu.:0.00000	1st Qu.:0.000
Median :0.0000	Median :0.0000	Median :0.00000	Median :0.000
Mean :0.4074	Mean :0.1799	Mean :0.06878	Mean :0.164
3rd Qu.:1.0000	3rd Qu.:0.0000	3rd Qu.:0.00000	3rd Qu.:0.000
Max. :1.0000	Max. :2.0000	Max. :1.00000	Max. :1.000

ftv	bwt
Min. :0.0000	Min. : 709
1st Qu.:0.0000	1st Qu.:2410
Median :1.0000	Median :2977
Mean :0.8783	Mean :2890
3rd Qu.:1.0000	3rd Qu.:3444
Max. :6.0000	Max. :4238

```
cat("\n--- Resumo Descritivo: Conjunto de TESTE/OOB (Iteração Seleccionada) ---\n")
```

```
--- Resumo Descritivo: Conjunto de TESTE/OOB (Iteração Seleccionada) ---
```

```
print(summary(df_oob_ideal))
```

low	age	lwt	race
Normal :47	Min. :15.00	Min. : 90.0	Min. :1.000
Baixo Peso:19	1st Qu.:19.00	1st Qu.:112.0	1st Qu.:1.000
	Median :21.50	Median :121.5	Median :1.000
	Mean :22.97	Mean :131.3	Mean :1.833
	3rd Qu.:25.00	3rd Qu.:139.5	3rd Qu.:3.000

	Max. :45.00	Max. :235.0	Max. :3.000
smoke	ptl	ht	ui
Min. :0.0000	Min. :0.000	Min. :0.00000	Min. :0.0000
1st Qu.:0.0000	1st Qu.:0.000	1st Qu.:0.00000	1st Qu.:0.0000
Median :0.0000	Median :0.000	Median :0.00000	Median :0.0000
Mean :0.3485	Mean :0.197	Mean :0.07576	Mean :0.1515
3rd Qu.:1.0000	3rd Qu.:0.000	3rd Qu.:0.00000	3rd Qu.:0.0000
Max. :1.0000	Max. :3.000	Max. :1.00000	Max. :1.0000
ftv	bwt		
Min. :0.0000	Min. :1135		
1st Qu.:0.0000	1st Qu.:2430		
Median :0.0000	Median :2977		
Mean :0.7424	Mean :3010		
3rd Qu.:1.0000	3rd Qu.:3625		
Max. :3.0000	Max. :4990		